

МАТРИЧНЫЕ РАЗЛОЖЕНИЯ

ПЛАН

- › Матричные разложения
- › SVD и “SVD”
- › Рекомендации
- › Тексты
- › Особенности обозначений

МАТРИЧНЫЕ РАЗЛОЖЕНИЯ

$$X \approx U \cdot V^T$$

$l \times n \quad l \times k \quad k \times n$

МАТРИЧНЫЕ РАЗЛОЖЕНИЯ

$$X \approx U \cdot V^T$$

$l \times n \quad l \times k \quad k \times n$

$$\|X - U \cdot V^T\| \rightarrow \min$$

МАТРИЧНЫЕ РАЗЛОЖЕНИЯ

$$X \approx U \cdot V^T$$

$l \times n$ $l \times k$ $k \times n$

$$\|X - U \cdot V^T\| \rightarrow \min$$

$$\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2}$$

МАТРИЧНЫЕ РАЗЛОЖЕНИЯ


$$X \approx U \cdot V^T$$

$l \times n \quad l \times k \quad k \times n$

$$\|X - U \cdot V^T\| \rightarrow \min$$


$$\sum_{i,j} (x_{ij} - \langle u_i, v_j \rangle)^2 \rightarrow \min$$

РАЗБИРАЕМСЯ С ОБОЗНАЧЕНИЯМИ



$$\mathbf{X} \approx \mathbf{U} \cdot \mathbf{V}^T$$

РАЗБИРАЕМСЯ С ОБОЗНАЧЕНИЯМИ





$$x_{ij} = \langle u_i, v_j \rangle$$

SVD В ЛИНЕЙНОЙ АЛГЕБРЕ

- » $X = U\Sigma V^T$
- » U — ортогональная
- » Σ — диагональная
- » V — ортогональная

SVD В ЛИНЕЙНОЙ АЛГЕБРЕ

» $X = U\Sigma V^T$



ПРИБЛИЖЕНИЕ МАТРИЦЫ С ПОМОЩЬЮ SVD

$$X \approx U \cdot V^T$$
$$l \times n \qquad l \times k \quad k \times n$$

$$\|X - U \cdot V^T\| \rightarrow \min$$

ПРИБЛИЖЕНИЕ МАТРИЦЫ С ПОМОЩЬЮ SVD

$$X \approx U \cdot V^T$$

$l \times n$ $l \times k$ $k \times n$

$$\|X - U \cdot V^T\| \rightarrow \min$$

$$X = \tilde{U} \Sigma \tilde{V}^T$$

ПРИБЛИЖЕНИЕ МАТРИЦЫ С ПОМОЩЬЮ SVD

$$X \approx U \cdot V^T$$

$l \times n$ $l \times k$ $k \times n$

$$\| X - U \cdot V^T \| \rightarrow \min$$

$$X = \tilde{U}\Sigma\tilde{V}^T$$

$$X_{(m \times n)} = \tilde{U}_{(m \times \tau)} \Sigma_{(\tau \times \tau)} \tilde{V}^T_{(\tau \times n)}$$

ПРИБЛИЖЕНИЕ МАТРИЦЫ С ПОМОЩЬЮ SVD

$$X \approx U \cdot V^T$$

$l \times n$ $l \times k$ $k \times n$

$$\|X - U \cdot V^T\| \rightarrow \min$$

$$X = \tilde{U} \Sigma \tilde{V}^T$$

» $\tilde{U}_k, \Sigma_k, \tilde{V}_k$ — усеченные матрицы из SVD

$$U = \tilde{U}_k \Sigma_k \quad V = \tilde{V}_k$$

ПРИБЛИЖЕНИЕ МАТРИЦЫ С ПОМОЩЬЮ SVD

$$X \approx U \cdot V^T$$

$l \times n$ $l \times k$ $k \times n$

$$\|X - U \cdot V^T\| \rightarrow \min$$

$$X = \tilde{U} \Sigma \tilde{V}^T$$

» $\tilde{U}_k, \Sigma_k, \tilde{V}_k$ — усеченные матрицы из SVD

$$U = \tilde{U}_k \quad V = \tilde{V}_k \Sigma_k$$

ПРИБЛИЖЕНИЕ МАТРИЦЫ С ПОМОЩЬЮ SVD

$$X \approx U \cdot V^T$$

$l \times n \quad l \times k \quad k \times n$

$$\|X - U \cdot V^T\| \rightarrow \min$$

$$X = \tilde{U} \Sigma \tilde{V}^T$$

» $\tilde{U}_k, \Sigma_k, \tilde{V}_k$ — усеченные матрицы из SVD

$$U = \tilde{U}_k \sqrt{\Sigma_k} \quad V = \tilde{V}_k \sqrt{\Sigma_k}$$

“SVD” В МАШИННОМ ОБУЧЕНИИ

$$X \approx U \cdot V^T$$

$l \times n$ $l \times k$ $k \times n$

$$\sum_{i,j} (x_{ij} - \langle u_i, v_j \rangle)^2 \rightarrow \min$$

- › u_i — “профили” объектов
- › v_j — “профили” исходных признаков

МАТРИЦА РЕЙТИНГОВ И SVD

	Пила	Улица Вязов	Ванильное небо	1+1
Маша	5	4	1	2
Юля	5	5	2	
Вова			3	5
Коля	3	?	4	5
Петя				4
Ваня		5	3	3

МАТРИЦА РЕЙТИНГОВ И SVD

	Пила	Улица Вязов	Ванильное небо	j 1+1
Маша	5	4	1	2
Юля	5	5	2	
Вова			3	5
Коля	3	?	4	5
Петя				4
Ваня		5	3	3

МАТРИЦА РЕЙТИНГОВ И SVD

	Пила	Улица Вязов	Ванильное небо	j 1+1
Маша	5	4	1	2
Юля	5	5	2	
Вова			3	5
Коля	3	?	4	5
Петя				4
Ваня		5	3	3

$$x_{ij} \approx \langle u_i, v_j \rangle$$

- › u_i — “интересы пользователей”
- › v_j — “параметры фильмов”

МАТРИЦА ЧАСТОТ СЛОВ И SVD

	database	SQL	index	regression	likelihood	linear
d1	24	21	9	0	0	3
d2	32	10	5	0	3	0
d3	12	16	5	0	0	0
d4	6	7	2	0	0	0
d5	43	31	20	0	3	0
d6	2	0	0	18	7	16
d7	0	0	1	32	12	0
d8	3	0	0	22	4	2
d9	1	0	0	34	27	25
d10	6	0	0	17	4	23

МАТРИЦА ЧАСТОТ СЛОВ И SVD

	database	SQL	index	regression	likelihood	linear
d1	24	21	9	0	0	3
d2	32	10	5	0	3	0
d3	12	16	5	0	0	0
d4	6	7	2	0	0	0
d5	43	31	20	0	3	0
d6	2	0	0	18	7	16
d7	0	0	1	32	12	0
d8	3	0	0	22	4	2
d9	1	0	0	34	27	25
d10	6	0	0	17	4	23

j

i

МАТРИЦА ЧАСТОТ СЛОВ И SVD


	database	SQL	index	regression	likelihood	linear
d1	24	21	9	0	0	3
d2	32	10	5	0	3	0
d3	12	16	5	0	0	0
d4	6	7	2	0	0	0
d5	43	31	20	0	3	0
d6	2	0	0	18	7	16
d7	0	0	1	32	12	0
d8	3	0	0	22	4	2
d9	1	0	0	34	27	25
d10	6	0	0	17	4	23

j

$$x_{ij} \approx \langle u_i, v_j \rangle$$


- » u_i — “темы” документов
- » v_j — “темы” слов

ЕЩЕ НЕМНОГО ПРО ОБОЗНАЧЕНИЯ




$$x_{ij} \approx \langle u_i, v_j \rangle$$

ЕЩЕ НЕМНОГО ПРО ОБОЗНАЧЕНИЯ





$$x_{ij} \approx \langle u_i, v_j \rangle$$


ЕЩЕ НЕМНОГО ПРО ОБОЗНАЧЕНИЯ





ЕЩЕ НЕМНОГО ПРО ОБОЗНАЧЕНИЯ




$$x_{ij} \approx \langle u_i, v_j \rangle$$



ЕЩЕ НЕМНОГО ПРО ОБОЗНАЧЕНИЯ




$$x_{ij} \approx \langle u_i, v_j \rangle$$



$$x_{ij} = u_i^T v_j$$

АНАЛОГИЯ С МАТРИЦЕЙ ПРИЗНАКОВ



➤ В линейных моделях: $\langle \mathbf{w}, \mathbf{x}_i \rangle = \mathbf{w}^T \mathbf{x}_i$



КАКИЕ ОБОЗНАЧЕНИЯ ВСТРЕЧАЮТСЯ

» $X = UV^T$

» $X = PQ^T$

» $X = WH^T$

» $X = \Phi\Theta$

SGD И ALS

ПЛАН

- › Постановка задачи
- › Градиентный спуск
- › Стохастический градиентный спуск
- › ALS
- › Регуляризация

ПОСТАНОВКА ЗАДАЧИ

$$Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min_{u_i, v_j}$$

ГРАДИЕНТНЫЙ СПУСК (GD)

- » $Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min_{u_i, v_j}$
- » $\frac{\partial Q}{\partial u_i} = \sum_{i,j} \frac{\partial}{\partial u_i} (\langle u_i, v_j \rangle - x_{ij})^2 =$
 $= \sum_j 2(\langle u_i, v_j \rangle - x_{ij}) \frac{\partial \langle u_i, v_j \rangle}{\partial u_i} =$
 $= \sum_j 2(\langle u_i, v_j \rangle - x_{ij}) v_j$
- » $\varepsilon_{ij} = (\langle u_i, v_j \rangle - x_{ij})$ — ошибка на x_{ij}

ГРАДИЕНТНЫЙ СПУСК (GD)

» $Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min_{u_i, v_j}$

$$\frac{\partial Q}{\partial u_i} = \sum_j 2(\langle u_i, v_j \rangle - x_{ij})v_j$$

» $\varepsilon_{ij} = (\langle u_i, v_j \rangle - x_{ij})$ — ошибка на x_{ij}

$$u_i^{(t+1)} = u_i^{(t)} - \gamma_t \sum_j \varepsilon_{ij} v_j$$

СТОХАСТИЧЕСКИЙ ГРАДИЕНТНЫЙ СПУСК (SGD)

GD:

$$u_i^{(t+1)} = u_i^{(t)} - \gamma_t \sum_j \varepsilon_{ij} v_j$$

$$v_j^{(t+1)} = v_j^{(t)} - \eta_t \sum_i \varepsilon_{ij} u_i$$



SGD:

$$u_i^{(t+1)} = u_i^{(t)} - \gamma_t \varepsilon_{ij} v_j$$

$$v_j^{(t+1)} = v_j^{(t)} - \eta_t \varepsilon_{ij} u_i$$

Для случайных i, j

Плюсы и минусы SGD

➤ Плюсы:

- ▶ Простота реализации
- ▶ Сходимость

➤ Минусы:

- ▶ Медленно сходится
- ▶ Сложность выбора шага градиентного спуска (γ_t и η_t)

ПЛЮСЫ И МИНУСЫ SGD

➤ Минусы:

- ▶ Медленно сходится
- ▶ Сложность выбора шага градиентного спуска (γ_t и η_t)
- ▶ При константном шаге сходится очень медленно

ИДЕЯ ALS

$$Q \rightarrow \min_{u_i, v_j}$$

› Повторяем до сходимости:

$$\frac{\partial Q}{\partial u_i} = 0 \rightarrow u_i$$

$$\frac{\partial Q}{\partial v_j} = 0 \rightarrow v_j$$

ВЫПИСЫВАЕМ ШАГ В ALS

$$Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min_{u_i, v_j}$$

- › $\frac{\partial Q}{\partial u_i} = \sum_j 2(\langle u_i, v_j \rangle - x_{ij})v_j = 0$
$$\sum_j v_j \langle v_j, u_i \rangle = \sum_j x_{ij} v_j$$
- › $\sum_j v_j v_j^T u_i = \sum_j x_{ij} v_j$
- › $\left(\sum_j v_j v_j^T \right) u_i = \sum_j x_{ij} v_j$

ALS: ИТОГОВЫЙ АЛГОРИТМ

› Повторяем по случайным i, j до сходимости:

$$\left(\sum_j v_j v_j^T \right) u_i = \sum_j x_{ij} v_j \rightarrow u_i$$

$$\left(\sum_i u_i u_i^T \right) v_j = \sum_i x_{ij} u_i \rightarrow v_j$$

(решение системы
линейных уравнений)

РЕГУЛЯРИЗАЦИЯ

- »
$$Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 + \alpha \sum_i \|u_i\|^2 + \beta \sum_j \|v_j\|^2 \rightarrow \min_{u_i, v_j}$$
- » α и β — небольшие положительные числа
(0.001, 0.01, 0.5)

РЕЗЮМЕ

- › Постановка задачи
- › Градиентный спуск
- › Стохастический градиентный спуск
- › ALS
- › Регуляризация

ПРОГНОЗИРОВАНИЕ НЕИЗВЕСТНЫХ ЗНАЧЕНИЙ В МАТРИЦЕ

ПЛАНЫ

- › Постановка задачи в рекомендациях
- › Модель прогнозирования неизвестных значений
- › Оптимизируемый функционал
- › Добавление сдвига
- › Добавление базовых предикторов

ПЛАНЫ

- › Модель прогнозирования неизвестных значений
- › Оптимизируемый функционал
- › Добавление сдвига
- › Добавление базовых предикторов
- › Регуляризация по базовым предикторам

ПОСТАНОВКА ЗАДАЧИ В РЕКОМЕНДАЦИЯХ

		j		
	Пила	Улица Вязов	Ванильное небо	1+1
Маша	5	4	1	2
Юля	5	5	2	
Вова			3	5
Коля	3	?	4	5
Петя				4
Ваня		5	3	3

МОДЕЛЬ ПРОГНОЗИРОВАНИЯ

j

	Пила	Улица Вязов	Ванильное небо	1+1
<i>i</i>				
Маша	5	4	1	2
Юля	5	5	2	
Вова			3	5
Коля	3	?	4	5
Петя				4
Ваня		5	3	3

$$x_{ij} \approx \langle u_i, v_j \rangle$$

u_i — «интересы пользователей»

v_j — «параметры фильмов»

ОПТИМИЗИРУЕМЫЙ ФУНКЦИОНАЛ

$$x_{ij} \approx \langle u_i, v_j \rangle$$

$$\sum_{i,j: x_{ij} \neq 0} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$

СДВИГ

$$x_{ij} \approx \boxed{\mu} + \langle u_i, v_j \rangle$$

$$\sum_{i,j} (\boxed{\mu} + \langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$

БАЗОВЫЕ ПРЕДИКТОРЫ

$$x_{ij} \approx \mu + \boxed{b_i^u} + \boxed{b_j^v} + \langle u_i, v_j \rangle$$

$$\sum_{i,j} (\mu + \boxed{b_i^u} + \boxed{b_j^v} + \langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$

РЕГУЛЯРИЗАЦИЯ

$$\sum_{i,j} (\mu + b_i^u + b_j^v + \langle u_i, v_j \rangle - x_{ij})^2 +$$

$$+ \alpha \sum_i \|u_i\|^2 + \beta \sum_j \|v_j\| +$$

$$+ \gamma \sum_i {b_i^u}^2 + \delta \sum_j {b_j^v}^2 \rightarrow \min$$

РЕЗЮМЕ

- › Постановка задачи в рекомендациях
- › Модель прогнозирования неизвестных значений
- › Оптимизируемый функционал
- › Добавление сдвига
- › Добавление базовых предикторов

РЕЗЮМЕ

- › Модель прогнозирования неизвестных значений
- › Оптимизируемый функционал
- › Добавление сдвига
- › Добавление базовых предикторов
- › Регуляризация по базовым предикторам

НЕГАТИВНЫЕ ПРИМЕРЫ И IMPLICIT РАЗЛОЖЕНИЯ

ПЛАН

- Рекомендации товаров
- Почему нельзя всё делать как обычно
- Implicit feedback
- Implicit matrix factorization: идея
- Implicit ALS

РЕКОМЕНДАЦИИ ТОВАРОВ

j

	Вечернее платье	Поднос для писем	iPhone 6s	Шуба D&G
Маша	1		1	
Юля	1	1		1
Вова		1	1	
Коля	1	?	1	
Петя		1	1	
Ваня			1	1

i

ПОЧЕМУ НУЖНО ЧТО-ТО МЕНЯТЬ

j

	Вечернее платье	Поднос для писем	iPhone 6s	Шуба D&G
Mаша	1		1	
Юля	1	1		1
Вова		1	1	
Коля	1	?	1	
Петя		1	1	
Ваня			1	1

i

$$x_{ij} = 1 \approx \langle u_i, v_j \rangle$$



$$u_i = \frac{1}{\sqrt{d}}(1 \dots 1)$$

$$\sum_{i,j: x_{ij} \neq 0} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$

$$v_j = \frac{1}{\sqrt{d}}(1 \dots 1)$$

EXPLICIT И IMPLICIT

- › **Explicit feedback:** есть положительные и отрицательные примеры (например, низкие и высокие оценки фильмов, лайки и дислайки и т.д.)
- › **Implicit feedback:** есть только положительные (покупки, просмотры, лайки) или только отрицательные примеры (дислайки)

IMPLICIT MATRIX FACTORIZATION

$$\sum_{i,j} w_{ij} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$



Сумма по всем индексам (не только по известным элементам матрицы)

- › w_{ij} принимает большие значения для $x_{ij} \neq 0$ и значительно меньшие для $x_{ij} = 0$

IMPLICIT ALS

$$\sum_{i,j} w_{ij} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$

$$w_{ij} = 1 + \alpha |x_{ij}| \quad \alpha = 10, 100, 1000$$

u_i, v_j оцениваем с помощью ALS

РЕЗЮМЕ

- Рекомендации товаров
- Почему нельзя всё делать как обычно
- Implicit feedback
- Implicit matrix factorization: идея
- Implicit ALS

ВЕРОЯТНОСТНАЯ ИНТЕРПРЕТАЦИЯ


ПЛАН

- › "SVD" и нормальное распределение
- › Какое распределение подходит больше
- › Распределение Пуассона
- › Неотрицательное матричное разложение
- › Другие неотрицательные матричные разложения

ПОСТАНОВКА ЗАДАЧИ В "SVD"

$$Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min_{u_i, v_j}$$

НОРМАЛЬНОЕ РАСПРЕДЕЛЕНИЕ



» $p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

СВЯЗЬ “SVD” И НОРМАЛЬНОГО РАСПРЕДЕЛЕНИЯ

$$\triangleright x_{ij} = \langle u_i, v_j \rangle + \varepsilon \quad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

$$x_{ij} \sim \mathcal{N}(\langle u_i, v_j \rangle, \sigma^2)$$

$$\triangleright \prod_{i,j} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_{ij} - \langle u_i, v_j \rangle)^2}{2\sigma^2}} \rightarrow \max$$


$$\triangleright \sum_{i,j} \frac{(x_{ij} - \langle u_i, v_j \rangle)^2}{2\sigma^2} - \frac{1}{2} \ln 2\pi\sigma^2 \rightarrow \min$$

$$\triangleright \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$

КАКОЕ РАСПРЕДЕЛЕНИЕ ПОДХОДИТ БОЛЬШЕ

	database	SQL	index	regression	likelihood	linear
d1	24	21	9	0	0	3
d2	32	10	5	0	3	0
d3	12	16	5	0	0	0
d4	6	7	2	0	0	0
d5	43	31	20	0	3	0
d6	2	0	0	18	7	16
d7	0	0	1	32	12	0
d8	3	0	0	22	4	2
d9	1	0	0	34	27	25
d10	6	0	0	17	4	23

РАСПРЕДЕЛЕНИЕ ПУАССОНА



$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda} \quad \mathbb{E}X = \lambda$$

РАСПРЕДЕЛЕНИЕ ПУАССОНА И МАТРИЧНЫЕ РАЗЛОЖЕНИЯ

- » $x_{ij} \sim Poiss\langle u_i, v_j \rangle$
- » $P(x_{ij}) = \frac{\langle u_i, v_j \rangle^{x_{ij}}}{x_{ij}!} e^{-\langle u_i, v_j \rangle}$
- » $\prod_{i,j} \frac{\langle u_i, v_j \rangle^{x_{ij}}}{x_{ij}!} e^{-\langle u_i, v_j \rangle} \rightarrow \max$
- » $\sum_{i,j} \langle u_i, v_j \rangle - x_{ij} \ln \langle u_i, v_j \rangle \ln x_{ij}! \rightarrow \min$
- » $\sum_{i,j} \langle u_i, v_j \rangle - x_{ij} \ln \langle u_i, v_j \rangle \rightarrow \min$

SGD ДЛЯ NMF (NON-NEGATIVE MATRIX FACTORIZATION)

- » $Q = \sum_{i,j} \langle u_i, v_j \rangle - x_{ij} \ln \langle u_i, v_j \rangle \rightarrow \min$
- » $\frac{\partial Q}{\partial u_i} = \sum_j v_j - \frac{x_{ij}}{\langle u_i, v_j \rangle} v_j =$
 $= \sum_j \frac{\langle u_i, v_j \rangle - x_{ij}}{\langle u_i, v_j \rangle} v_j \rightarrow \min$
 $\tilde{\varepsilon}_{ij}$ - "относительная ошибка прогноза"

SGD:

$$u_i^{(t+1)} = u_i^{(t)} - \gamma_t \tilde{\varepsilon}_{ij} v_j$$
$$v_j^{(t+1)} = v_j^{(t)} - \eta_t \tilde{\varepsilon}_{ij} u_i$$

ДРУГИЕ НЕОТРИЦАТЕЛЬНЫЕ МАТРИЧНЫЕ РАЗЛОЖЕНИЯ

- Можно использовать норму Фробениуса, но добавить ограничения неотрицательности для U и V :


$$Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min_{\substack{u_i, v_j: \\ u_{ik} \geq 0 \\ v_{jk} \geq 0}}$$

РЕЗЮМЕ

- › "SVD" и нормальное распределение
- › Какое распределение подходит больше
- › Распределение Пуассона
- › Неотрицательное матричное разложение
- › Другие неотрицательные матричные разложения

НЕОТРИЦАТЕЛЬНЫЕ МАТРИЧНЫЕ РАЗЛОЖЕНИЯ: ПОСТАНОВКА И РЕШЕНИЕ

МАТРИЧНЫЕ РАЗЛОЖЕНИЯ



$$r < \min(n, m)$$

$$(W^*, H^*) = \underset{W, H}{\operatorname{argmin}} D(X, WH)$$

НЕОТРИЦАТЕЛЬНЫЕ МАТРИЧНЫЕ РАЗЛОЖЕНИЯ (NMF)

$$D(X, \hat{X}) = \sum_{i=1}^n \sum_{j=1}^m d(x_{ij}, \hat{x}_{ij})$$

» Обозначим $\hat{X} = WH$.

$$D(X, \hat{X}) = \sum_{i=1}^m \sum_{j=1}^n d(x_{ij}, \hat{x}_{ij})$$

» Чаще всего в качестве функции потерь берут норму Фробениуса:

$$d_F(x, \hat{x}) = (x - \hat{x})^2$$

$$D_F(X, \hat{X}) = \sum_{i=1}^n \sum_{j=1}^m (x_{ij} - \hat{x}_{ij})^2 \equiv \|X - WH\|_F^2$$

ПРОБЛЕМЫ НМФ

- › Некорректно поставлена: если W_0, H_0 — решение, то $W = W_0 Y, H = Y^{-1} H_0$ тоже может быть решением.
- › $D(X, WH)$ не выпукла по совокупности аргументов $(W, H) \rightarrow$ блочно-покоординатные методы минимизации:
Вход: $W^0 \geq 0, H^0 \geq 0$

Цикл

$$\begin{aligned}H &\leftarrow f(X, W, H), \\W &\leftarrow g(X, W, H)\end{aligned}$$

$(f(X, W, H) = g^T(X^T, H^T, W^T),$
поскольку задача симметрична)

NMF С НОРМОЙ ФРОБЕНИУСА

- » Оптимизационная задача:

$$(W^*, H^*) = \underset{W \geq 0, H \geq 0}{\operatorname{argmin}} \|X - WH\|_F^2$$

- » Без ограничения неотрицательности решение можно было бы получить с помощью SVD.

- » Базовый метод — поочерёдный градиентный спуск:

$$h_{kj} \leftarrow h_{kj} - \nu_{kj} \frac{\partial D_F}{\partial h_{kj}}$$

$$w_{ik} \leftarrow w_{ik} - \eta_{ik} \frac{\partial D_F}{\partial w_{ik}}$$

$$k = 1, \dots, r, \quad i = 1, \dots, n, \\ j = 1, \dots, m$$

МУЛЬТИПЛИКАТИВНЫЕ ОБНОВЛЕНИЯ

- › Идея: выбрать шаги градиентного спуска так, чтобы обновления стали мультипликативными.

$$\frac{\partial D_F}{\partial h_{kj}} = \sum_{i=1}^n w_{ik} \hat{x}_{ij} - \sum_{i=1}^n w_{ik} x_{ij}, \nu_{kj} = \frac{h_{kj}}{\sum_{i=1}^n w_{ik} \hat{x}_{ij}}$$

$$h_{kj} \leftarrow h_{kj} - \frac{h_{kj}}{\sum_{i=1}^n w_{ik} \hat{x}_{ij}} \left(\sum_{i=1}^n w_{ik} \hat{x}_{ij} - \sum_{i=1}^n w_{ik} x_{ij} \right) = \\ = h_{kj} \frac{\sum_{i=1}^n w_{ik} x_{ij}}{\sum_{i=1}^n w_{ik} \hat{x}_{ij}}$$

МУЛЬТИПЛИКАТИВНЫЕ ОБНОВЛЕНИЯ

- » В матричном виде:

$$H \leftarrow H \otimes (W^T X) \oslash (W^T \hat{X})$$

\otimes — поэлементное умножение матриц
 \oslash — поэлементное деление

- » Функция потерь монотонно невозрастает

МУЛЬТИПЛИКАТИВНЫЕ ОБНОВЛЕНИЯ

- Методы с мультипликативными обновлениями популярны, потому что они:
 - ▶ просты в реализации;
 - ▶ хорошо масштабируются и легко приспосабливаются к работе с разреженными матрицами;
 - ▶ были предложены в самой первой работе по NMF.
- Скорость сходимости невелика, но её можно увеличить, если обновлять W и H по несколько раз подряд.

МЕТОД ПОПЕРЕМЕННЫХ НАИМЕНЬШИХ КВАДРАТОВ

- » Alternating Least Squares (ALS): на каждом шаге находится решение задачи наименьших квадратов по одной из компонент, затем проецируется на неотрицательную область.

$$\begin{aligned} H &\leftarrow \max \left(\underset{H}{\operatorname{argmin}} \|X - WH\|_F^2, 0 \right) = \\ &= \max \left((W^T W)^{-1} W^T X, 0 \right) \end{aligned}$$

- » Метод быстрый, но грубый: итерационный процесс не сходится, функция потерь осциллирует. Можно использовать для инициализации других методов.

МЕТОД ПОПЕРЕМЕННЫХ НЕОТРИЦАТЕЛЬНЫХ НАИМЕНЬШИХ КВАДРАТОВ

- › Alternating Nonnegative Least Squares (ANLS): на каждом шаге точно находится покомпонентный минимум в неотрицательной области.

$$H \leftarrow \underset{H \geq 0}{\operatorname{argmin}} \|X - WH\|_F$$

- › Метод точный, но медленный: каждая итерация требует существенных вычислительных затрат. Можно использовать для уточнения решения, найденного более простыми методами.

МЕТОД ИЕРАРХИЧЕСКИХ ПОПЕРЕМЕННЫХ НАИМЕНЬШИХ КВАДРАТОВ

- ▶ Hierarchical alternating least squares (HALS): на каждом шаге точно находится минимум в неотрицательной области по столбцу w_k или строке h_k .

$$\begin{aligned} h_k &\leftarrow \underset{h_k \geq 0}{\operatorname{argmin}} \|X - WH\|_F = \\ &= \max \left(0, \frac{w_k^T X - \sum_{l \neq k} w_k^T w_l h_l}{w_k^T w_k} \right) \end{aligned}$$

- ▶ на каждом шаге вычислительные затраты небольшие
- ▶ сходится быстрее метода мультипликативных обновлений
- ▶ чувствителен к начальному приближению

РЕЗЮМЕ

- › Неотрицательное матричное разложение, постановка и проблемы задачи
- › Методы решения для нормы Фробениуса

ДАЛЕЕ В ПРОГРАММЕ

- › Другие функции потерь
- › Инициализация

НЕОТРИЦАТЕЛЬНЫЕ МАТРИЧНЫЕ РАЗЛОЖЕНИЯ: ФУНКЦИОНАЛЫ И ИНИЦИАЛИЗАЦИЯ

НЕОТРИЦАТЕЛЬНЫЕ МАТРИЧНЫЕ РАЗЛОЖЕНИЯ (NMF)

$$(W^*, H^*) = \underset{W \geq 0, H \geq 0}{\operatorname{argmin}} D(X, WH)$$

ФУНКЦИИ ПОТЕРЬ

$$D(X, \hat{X}) = \sum_{i=1}^n \sum_{j=1}^m d(x_{ij}, \hat{x}_{ij})$$

$$d(x, \hat{x}) \geq 0, \quad d(x, \hat{x}) = 0 \Leftrightarrow x = \hat{x}$$

Название	$d(x, \hat{x})$
норма l_1	$d_1(x, \hat{x}) = x - \hat{x} $
норма Фробениуса	$d_F(x, \hat{x}) = (x - \hat{x})^2$
обобщённая дивергенция Кульбака-Лейблера	$d_{KL}(x, \hat{x}) = x \ln \frac{x}{\hat{x}} - x + \hat{x}$
дивергенция Итакура-Сайто	$d_{IS}(x, \hat{x}) = \ln \frac{\hat{x}}{x} + \frac{x}{\hat{x}} - 1$
расстояние Хеллингера	$d_H(x, \hat{x}) = \left(\sqrt{x} - \sqrt{\hat{x}} \right)^2$

ФУНКЦИИ ПОТЕРЬ

- » Часто функция потерь — это замаскированное правдоподобие: существует такая плотность $p(X|\hat{X})$, что
- $$D(X, \hat{X}) \propto -\ln p(X|\hat{X})$$

Функция потерь	Порождающая модель
Фробениуса	аддитивная гауссовская
Кульбака-Лейблера	пуассоновская
Итакура-Сайто	мультипликативная гамма

С ДИВЕРГЕНЦИЕЙ КУЛЬБАКА-ЛЕЙБЛЕРА

- » Мультипликативные обновления:

$$h_{kj} \leftarrow h_{kj} \frac{\sum_{i=1}^n w_{ik} x_{ij}}{\sum_{i=1}^n w_{ik} \hat{x}_{ij}}$$

- » Функция потерь монотонно невозрастает
- » Тот же функционал, но по-другому, минимизирует метод PLSA (скоро в программе!)

ИНИЦИАЛИЗАЦИЯ

› Поскольку методы сходятся локально, начальное приближение играет большую роль.

- ▶ Случайная инициализация
- ▶ Кластеризация
- ▶ SVD
- ▶ ALS
- ▶ Мультистарт:
 1. С помощью ALS генерируются 10-20 пар матриц
 2. Делаются 10-20 итераций целевого метода на каждой паре
 3. В качестве начального приближения выбирается пара с наименьшим значением функционала

РЕЗЮМЕ

- › Функции потерь
- › Инициализация

ОБРАБОТКА ПРОПУСКОВ

ПРОПУСКИ

Матрица данных: $\mathbf{X} \in \mathbb{R}^{\ell \times d}$

Часть наблюдений пропущена.

- › Можно ли заполнить пропуски?
- › Если \mathbf{X} — матрица объекты-признаки, как с ней делать классификацию или регрессию?

СЛУЧАЙНОСТЬ ПРОПУСКОВ

- ▶ Предполагаем, что пропуски в матрице располагаются случайно.
- ▶ Пример исключений:
 - ▶ отказ респондентов отвечать на вопрос
 - ▶ Абрахам Вальд и повреждения самолётов

ОТБРАСЫВАНИЕ

- Можно выбросить объекты, для которых значение хотя бы одного признака пропущено (перед этим лучше избавиться от сильно разреженных признаков).
⇒ информация теряется

ЗАПОЛНЕНИЕ

- › По ближайшему объекту: для строки x_{i_1} находим самую похожую на неё x_{i_2} и заменяем $x_{i_1j} = NA$ на x_{i_2j}
- › Заполнение средними или медианами по столбцу
- › ЕМ-алгоритм
- › Матричные разложения

⇒ информация берётся из ниоткуда?

ДРУГОЙ СПОСОБ ОБРАБОТКИ

- » В некоторых задачах матрица X используется только для подсчёта величин вида $\frac{1}{\ell} X^T X$ и $\frac{1}{\ell} X^T y$
- » Можно считать их только полными парами:

$$\begin{aligned}\frac{1}{\ell} (X^T X)_{jk} &= \frac{1}{\ell} \sum_{i=1}^{\ell} x_{ij} x_{ik} \approx \\ &\approx \frac{1}{\ell_{jk}} \sum_{i=1}^{\ell} x_{ij} x_{ik} [x_{ij} \neq NA, x_{ik} \neq NA]\end{aligned}$$

ℓ_{jk} — число полных пар
 \Rightarrow информация не исчезает и не появляется из ниоткуда

ЕЩЁ ДЕТАЛИ

- › Пропуски в категориальных переменных удобно закодировать отдельной категорией (работает и для неслучайных пропусков!)
- › Для деревьев пропуски в непрерывных признаках можно заполнить значением, сильно отличающимся от всех остальных значений признака (-99999999), тогда они будут попадать в отдельный лист
- › Обработка по умолчанию в некоторых методах плохая (регрессия, отбрасывание), в некоторых — хорошая (xgboost, сложно).

РЕЗЮМЕ

- › Пропуски
- › Заполнение и отбрасывание